

Análisis Predictivo - 2025Q2

Examen 3

Competencia Kaggle



Catalina Trevisan - 64990

Introducción


Objetivo: predecir si un ítem es nuevo o usado.

Train shape: (70.000, 45)

Test shape: (30.000, 44)

Paso inicial: **Validación adversarial**


- AUC = 0.63 → Train y test similares
- Permite usar validación cruzada estándar sin riesgo de sobreajuste



A partir de 44 variables → **156 features**

Tipos de features:


- **Numericas**: log(precio), ratios (precio actual/base), diferencias, unidades vendidas
- **Temporales**: duración del listing, mes/día de publicación/actualización
- **Textuales**: longitud del título, proporción de mayúsculas/dígitos, palabras clave ('nuevo', 'usado')
- **Vendedor y atributos**: reputación, frecuencia de publicaciones, tienda oficial, envío, garantía, cantidad de imágenes
- **Interacciones**: combinaciones de features que capturan relaciones no lineales



**Feature
Engineering**

Procesamiento de texto y categóricas

- **TF-IDF:** transforma títulos en vectores numéricos
Detecta palabras clave y patrones semánticos
- **Label Encoding:** convierte variables categóricas en números
Permite al modelo “entender” el contenido textual sin perder información



Entrenamiento y validación

Validación cruzada estratificada 10 folds → mantiene proporción de clases

Modelos entrenados:

- **LightGBM**: rápido y eficiente
- **XGBoost**: alta capacidad de generalización
- **CatBoost**: maneja categóricas eficientemente

Parámetros: learning rate 0.02, profundidad 9, early stopping

5 semillas → promedio de resultados → **AUC ≈ 0.9985**

ENSEMBLE PONDERADO

Combinación de modelos:

- LightGBM: 35%
- XGBoost: 35%
- CatBoost: 30%

suaviza errores individuales → predicción más robusta

1. Pseudo-Labeling

- Agrega predicciones confiables del test como etiquetas
- Dataset ampliado +23 filas → mejor generalización



1. Optimización de threshold

- Threshold óptimo: 0.4836
- Mejora F1-score → Accuracy ~98%



Mejoras adicionales

Resultados

Modelo final: Ensemble + pseudo-labeling + threshold optimizado

AUC validación: 0.9985

Competencia Kaggle:

- Score público: 0.90700
- Score privado: 0.90911

Posibles mejoras futuras:

- Búsqueda de hiperparámetros más fina
- Stacking con meta-modelo
- Análisis más profundo de importancia de variables (SHAP Values)



Muchas
gracias

